

联邦学习

姜孟冯^{1,2}

(1. 中国矿业大学, 徐州; 2. 应急管理部信息研究院, 北京)

日期: 2025 年 7 月 1 日

1 背景概述

1.1 联邦学习简介

在数字化转型的浪潮中, 数据已成为驱动人工智能发展的核心燃料, 但传统的数据集中式处理方法要求将分散在各个终端或机构的数据集中到统一服务器进行模型训练, 这会带来额外的隐私风险。欧盟的《通用数据保护条例》、中国的《网络安全法》、《数据安全法》和《个人信息保护法》, 也严格规范了数字应用对用户隐私数据的使用限制与保护义务。如何在满足数据隐私、安全和监管要求的前提下, 设计一个机器学习框架, 让人工智能系统能够更加高效、准确的共同使用各自的数据, 是当前人工智能发展的一个重要课题。

联邦学习 (Federated Learning) 作为一种创新的分布式机器学习框架, 正在重新定义人工智能时代的协作模式, 为解决数据孤岛与隐私保护这对矛盾提供了革命性方案。其核心突破在于提出了“数据不动模型动”的逆向思维, 让模型在分布式节点间流动, 而原始数据始终保留在本地。它避免了将用户的敏感数据上传到中心服务器, 使得设备能够在本地数据集上进行本地训练并共享模型参数。

1.2 联邦学习的发展

- 1996 年, Cheung 等首次探讨了如何在分布式数据库环境中发掘关联规则^[1];
- 2006 年, Yu 等提出一种在横向和纵向分割的数据环境中, 实施能够保护隐私的分布式支持向量机构建方法^[2];
- 2016 年, McMahan 等人提出联邦学习算法应用于移动互联网手机终端的隐私保护, 联邦学习这一术语正式诞生^[3];
- 2019 年, 微众银行杨强等人扩展了联邦学习的定义, 并发布联邦学习开源框架 FATE^[4];
- 2022 年, IEEE 正式发布联邦学习首个国际标准《IEEE 3652.1-2020-IEEE Guide for Architectural Framework and Application of Federated Machine Learning》^[5];

2 定义与分类

2.1 联邦学习定义

联邦学习是一种分布式机器学习范式, 允许多个数据特有者在不共享他们的原始数据的情况下协同训练机器学习模型。通过联邦学习, 各参与方不再需要共享原始数据本身, 而是仅交换模型信息和更新数据, 就可以提升模型的性能。

场景描述: 假设有 m 个参与联邦学习的客户端 $C = C_1, \dots, C_m$, 第 i 个客户端 C_i 拥有自己的私有数据集 $D_i = \{(x_j^{(i)}, y_j^{(i)})\}_{j=1}^{N_i}$, 其中 $N_i = |x^{(i)}|$, 并且 $N = \sum_{i=1}^m N_i$ 。客户端 C_i 通常会拥有一个可学习的本

地模型或初始化后的模型 θ_i 。

联邦学习可以使每个客户端 C_i 在不向其他客户端 $C_{j \neq i}$ 透露其私有数据集 D_i 的前提下，共同训练一个全局模型 θ 。整个联邦学习过程的目标函数可以定义为：

$$\min \mathcal{L}(\theta) = \min \sum_{i=1}^m \frac{N_i}{N} \mathcal{L}_i(\theta)$$

其中， $\mathcal{L}_i$ 表示第 i 个客户端 C_i 的本地损失函数，是基于客户端 C_i 的数据 D_i 和全局模型 θ 进行计算的。

在联邦学习中，每个客户端使用其本地数据独立训练模型，计算得到梯度或更新后的模型参数。在基于“客户端-服务器”的中心化联邦学习架构中，梯度或模型参数随后会被发送到中心服务器，服务器负责聚合这些更新，以更新全局模型。

2.2 FedAvg 算法

在 2016 年，McMahan 等人提出了最初的联邦学习算法 FedAvg，这标志着联邦学习算法研究的开端。

图 1 以 FedAvg 算法为例展示了联邦学习的整体流程：




图 1: FedAvg 算法

- ① 初始化全局模型: 服务器首次初始化全局模型的参数 θ_1 。初始参数可能基于先前的知识或随机生成，为分布式训练提供了出发点。
- ② 选择客户端: 在每一训练轮次开始时，服务器根据一定的标准从所有客户端中选择一部分参与该轮训练。选择的标准可以是客户端的数据多样性、网络状态或者设备性能等。
- ③ 模型分发: 服务器将第 t 通信轮次下的全局模型参数 θ_t 发送到选中的客户端。这确保了所有参与当前轮次训练的客户端从相同的模型状态开始他们的本地训练。
- ④ 本地训练: 选中的客户端各自在自己持有的数据 D_i 上进行模型的训练。这一步涉及在本地数据上应用一定次数的优化算法 (如随机梯度下降算法)，以调整和优化模型参数。
- ⑤ 收集更新: 训练完成后，每个客户端 C_i 将基于本地数据 D_i 更新好的本地模型参数 $\theta_{t,k}^i$ 上传至服务器。在实际应用中，可通过安全的通信协议进行，以确保更新过程的隐私性和安全性。
- ⑥ 参数聚合: 服务器接收所有上传的模型更新，并将它们合并到全局模型中。在 FedAvg 算法中，这一步通常是计算所有更新的加权平均，以形成新的全局模型参数。

2.3 联邦学习的分类

- 按照数据特征划分: 可分为
 - 横向联邦学习 (Horizontal FL)
 - 纵向联邦学习 (Vertical FL)
 - 联邦迁移学习 (F Transfer L)

- 按照客户端类型划分：可分为
 - 跨设备的联邦学习（Cross-device FL）
 - 跨孤岛的联邦学习（Cross-silo FL）
- 按照系统拓扑结构划分，可分为
 - 中心化联邦学习（Centralized FL）
 - 去中心化联邦学习（Decentralized FL）

3 难点研究

3.1 数据异质性（Data Heterogeneity）

联邦学习中的数据异质性是指参与联邦学习的各客户端所持有的本地数据集在统计分布上存在显著差异，违背了独立同分布（Independent and Identically Distributed, IID）假设的现象，即数据呈现非独立同分布（Non-IID）特性。数据异质性的主要诱因可归纳为以下几类：(1) 用户个体行为差异；(2) 地理区域特征差异；(3) 终端设备类型差异；(4) 数据来源多样性差异；(5) 本地数据预处理与特征工程策略差异。这些系统性差异可能对联邦模型的训练过程及最终性能产生多方面的显著负面影响，具体表现如下：

- **模型性能劣化（Model Performance Degradation）**：客户端本地模型与全局模型优化目标之间的偏离，可能导致全局模型的整体预测准确性下降。这种偏差阻碍全局模型有效捕捉并泛化所有客户端的共性特征，进而损害其在未见数据上的泛化表现。
- **学习效率降低（Reduced Learning Efficiency）**：客户端漂移现象不仅引发性能问题，更显著增加了模型收敛的难度。本地模型更新过程中的偏差累积，通常迫使全局模型需要更多的通信轮次才能达到收敛状态，从而大幅提升了训练时间成本与计算资源消耗。
- **模型泛化能力减弱（Impaired Model Generalization）**：由客户端漂移导致的模型偏差，极易引发模型在特定客户端数据上的过拟合，而在其他客户端分布或全新数据域上的表现显著下降。这严重制约了模型的泛化能力，削弱了其在实际部署环境中的鲁棒性与可靠性。
- **系统稳定性挑战（System Stability Challenges）**：在客户端间数据分布差异极端显著的情况下，客户端漂移可能诱发系统的不稳定性。这种不稳定性常表现为模型输出的剧烈波动，导致预测结果难以预测与控制，威胁系统的稳健运行。

这些由数据异质性引发的挑战构成了联邦学习走向大规模实用化的关键障碍之一，研究者们积极探索多种创新路径以弥合数据异质性鸿沟，当前研究热点主要聚焦于以下五大技术方向：

1. 正则化方法 (Regularization Approaches)：通过在客户端本地模型更新过程中引入特定的正则化约束项，对本地优化方向进行校准。该方法旨在提升本地训练的稳定性，并有效弥合本地模型与全局模型之间的偏差。代表性方法包括：FedProx^[6]、SCAFFOLD^[7]、FedDyn^[8]。

2. 知识蒸馏技术 (Knowledge Distillation Techniques)：将知识蒸馏范式应用于联邦学习框架。其核心思想在于利用全局模型或本地模型作为教师模型，通过知识迁移过程（如在客户端执行全局模型到本地模型的蒸馏，或在服务器端聚合本地模型知识并蒸馏至全局模型）来缓解数据异质性带来的负面影响，典型案例如 FedFTG^[9] 方法。

3. 模型拆分与个性化 (Model Splitting and Personalization)：通过将神经网络模型结构性地拆解为共享层和个性化层。共享层参与联邦聚合以学习全局表征，而个性化层则在客户端本地保留或微调，旨在捕获特定于客户端的特征，从而在共享全局知识的基础上实现模型个性化。

4. 多任务学习框架 (Multi-Task Learning Frameworks)：将联邦学习建模为一个多任务学习问题，其中每个客户端的学习任务被视为一个独立但相关的任务。该框架的核心在于设计共享的模型参数或表征空间，促进任务间的知识共享与迁移，以协同提升所有客户端任务的性能。

5. 元学习策略 (Meta-Learning Strategies): 应用元学习的范式。该方法旨在从历史任务或客户端数据分布中学习一个高效的泛化先验或优化器。当面临新的客户端或数据分布时, 该先验能够指导模型利用少量本地更新步骤快速适应, 从而高效地获得性能良好的个性化模型。

3.2 模型异质性 (Model Heterogeneity)

模型异质性反映了参与联邦学习的各客户端在模型需求、计算能力或任务优先级方面存在的差异。这种差异可能源于客户端的硬件配置、数据处理能力、能源约束, 或是特定应用场景下的独特需求。与数据异质性不同, 模型异质性关注的是客户端本地模型本身的多样性, 而非数据分布。模型异质性的存在对联邦学习算法提出了额外的、独特的挑战, 在追求全局模型效能和通信效率的同时, 还需有效容纳并服务于各客户端的个性化模型需求。

模型异质性可依据其表现形式主要归纳为以下几类:

- **结构异质性:** 客户端使用的模型架构存在根本性差异。例如, 资源丰富的客户端可能部署深度神经网络, 而资源受限的客户端则可能只能运行轻量级模型 (如线性回归、决策树或小型 CNN)。
- **参数异质性:** 即使客户端采用相同的模型架构, 也可能根据本地数据特性或优化目标调整关键训练参数, 如学习率、正则化强度、批大小等, 以最大化本地性能。
- **功能异质性:** 不同客户端可能服务于截然不同的任务目标, 导致所需模型类型不同。例如, 部分客户端需要分类模型, 而其他客户端可能需要回归模型或聚类模型。

为应对不同客户端模型异质性带来的独特挑战, 亟需突破传统同构联邦框架的局限, 当前前沿研究主要聚焦以下创新路径:

1. 知识蒸馏技术 (Knowledge Distillation Techniques):

利用知识蒸馏的“模型无关”特性 (教师模型与学生模型架构可不同), 成为解决模型异质性的天然适配方案。其核心思想是让不同结构的本地模型 (或一个强大的全局教师模型) 通过交换输出层知识或中间特征表示进行协作学习, 而非直接交换模型参数。例如: Li 等人提出的 FedMD 框架让异构客户端在私有数据上独立训练, 然后通过蒸馏在公共数据集上交换知识, 实现知识迁移与模型个性化。

2. 基于部分训练的联邦优化算法 (Federated Optimization with Partial Training):

这类方法的核心是在模型分发阶段进行适配。服务器根据每个客户端的实时或预设资源能力, 从全局模型中动态提取一个相匹配的子模型发送给该客户端进行本地训练, 而非强制使用完整模型。子模型的提取策略可选择: 随机模式、静态模式或滚动模式。这种方法的优势在于能直接适配客户端资源, 且避免了知识蒸馏通常对公共代理数据集的依赖, 降低了数据获取和隐私泄露的风险。本地训练完成后, 只有子模型对应的参数更新被上传并聚合回全局模型。

3.3 通信挑战 (Communication Challenges)

通信瓶颈也是成为制约联邦学习实用化的系统性梗阻。联邦学习的核心范式依赖于分布在同一网络中的多客户端通过迭代式交换模型参数 (或更新) 来协同训练全局模型。然而, 客户端的地理分散性、网络环境异构性及资源受限特性, 使得通信过程面临严峻约束, 主要体现为以下关键问题:

- **网络带宽限制 (Bandwidth Constraints):** 参与联邦学习的客户端可能分布在不同的网络位置, 其可用上/下行带宽存在显著差异且普遍有限。在每轮通信中传输高维模型参数极易引发网络拥塞, 导致通信成本高昂, 甚至阻碍低带宽客户端的有效参与。
- **通信延迟 (Communication Latency):** 长距离传输、网络路径不稳定或高跳数路由会引入显著的端到端延迟。这种延迟不仅拖慢单轮通信时间, 更会因等待慢速客户端响应而阻塞全局聚合过程, 严重降低训练效率并损害系统实时性。

- **隐私与安全开销 (Privacy and Security Overheads)**: 虽然联邦学习避免了原始数据共享, 但传输的模型参数或梯度更新仍可能泄露敏感信息 (如通过模型反演或成员推断攻击)。为确保通信安全与隐私保护, 通常需引入加密、差分隐私噪声等安全机制, 这又进一步加剧了通信的复杂性和网络开销。
- **客户端能源消耗 (Client Energy Consumption)**: 对于电池供电的移动/物联网设备, 频繁且高强度的无线通信是主要的能耗来源, 低效的通信设计会加速设备电量耗尽, 降低用户参与意愿, 威胁系统的可持续运行。

面对通信-计算-隐私的三重约束, 优化设计需在约束边界内寻求帕累托改进, 当前主流技术路径沿三个关键维度推进:

- 1. 量化压缩 (Quantization)**: 将高精度浮点数模型参数转换为低精度表示甚至二元/三元值, 直接降低传输数据量。根据量化策略可分为: (1) 随机量化、(2) 旋转量化 (3) 符号量化等方式。
- 2. 稀疏化压缩 (Sparsification)**: 仅传输最重要的部分更新值 (如梯度 Top-k 值), 其余置零, 避免传递完整梯度。按稀疏化技术可分为: (1) 自适应稀疏化、(2) 双向稀疏化、(3) 分层稀疏化。常见稀疏化策略包括: 如 Top-k 稀疏化, Rand-k 稀疏化等。
- 3. 客户端选择优化 (Client Selection Optimization)**: 通过智能筛选参与者降低通信负载并规避瓶颈节点, 动态评估客户端状态 (如网络带宽、电量、计算能力), 优先选择“优质”客户端参与本轮训练。代表性算法如 FedCS^[10]: 设定时间窗口, 仅聚合能在窗口内完成本地训练并上传更新的客户端, 最大化选择限定时间内参与的客户端数量。

3.4 隐私安全挑战 (Privacy and Security Challenges)

联邦学习虽通过原始数据本地化规避了直接隐私泄露风险, 但其分布式协作机制仍面临严峻的安全威胁, 主要体现为两类主动威胁与一类被动威胁:

投毒攻击 (Poisoning Attacks) 是危害最大的主动威胁, 攻击者通过控制恶意客户端操纵训练过程。其中:

(1) **拜占庭攻击 (Byzantine Attacks)** 旨在无差别破坏模型性能 (如上传随机梯度), 导致全局模型失效。防御方法主要是强化聚合机制或入侵检测:

- 几何过滤法 (如 Krum) 通过计算更新向量间的欧氏距离分数, 排除离群更新;
- 统计修剪法 (如中位数/截断均值聚合) 直接剔除梯度分布的异常值;
- 动态检测法 (如 FLDetector^[11]) 利用历史更新预测当前值, 通过多轮一致性分析识别恶意客户端;
- 混合方法 (如 FedInv^[12]) 通过模型反演生成虚拟数据, 结合 Wasserstein 距离评估更新相似性。

(2) **后门攻击 (Backdoor Attacks)** 则更具隐蔽性, 攻击者注入特定触发器使模型在目标样本上输出指定结果。典型手段模型替换攻击 (Model Replacement Attack) 通过构造恶意更新迫使服务器聚合后门模型。防御方法有剪枝加噪 (如 CRFL 框架)、毒化检测 (如 BeFFLe)、更新验证 (如 DiverseFL) 等。

推断攻击 (Inference Attacks) 作为被动威胁, 攻击者通过分析共享的模型更新反推隐私信息: 成员推断 (Membership Inference) 判定特定样本是否参与训练; 属性推断 (Property Inference) 提取敏感属性; 重构攻击 (Reconstruction Attacks) 直接重建原始数据。

此类攻击的防御聚焦于阻断梯度信息泄露:

- 噪声注入法 (如分层自适应差分隐私) 在训练或传输阶段注入噪声, 降低更新信息的可逆性;
- 密码增强法 (如梯度加密、梯度分片重构) 通过加密机制阻断更新信息的可读性;
- 主动防御法 (如梯度相似性陷阱) 通过设计诱饵, 在攻击者反演梯度时触发诱饵特征, 识别恶意客户端。

3.5 开源实现

- 微众银行: FATE: <https://github.com/FederatedAI/FATE>
- 谷歌: Tensorflow-Federated: <https://github.com/google-parfait/tensorflow-federated>
- OpenMined: PySyft: <https://github.com/OpenMined/PySyft>
- 百度飞桨: PaddleFL: <https://github.com/PaddlePaddle/PaddleFL>
- 阿里: FederatedScope: <https://github.com/alibaba/FederatedScope>
- 蚂蚁隐语: secretflow: <https://github.com/secretflow/secretflow>
- 京东数科: fedlearn: <https://github.com/fedlearnAI/fedlearn>

可见，联邦学习作为机器学习与隐私保护计算交叉领域的前沿范式，已被众多科技企业及开源社区付诸工程实践，其标准化框架的涌现显著降低了研究门槛，有力促进了学术界对技术演进的深度参与与协同创新。

4 联邦学习应用

4.1 金融行业

金融行业是联邦学习应用最快的领域之一，其业务全链条存在数据孤岛与隐私合规冲突，各大金融机构通过联邦学习分布式建模实现跨机构协同。2019 年微众银行发布工业级联邦学习开源框架 FATE^[4]，包括诸如 LR、GBDT、CNN 等 20 多个算法组件，并用其打造了联邦推荐系统，在优化用户画像、定制化推送策略等方面进行了广泛应用。2020 年京东数科推出自主研发的联邦学习平台 Fedlearn^[13]，实现了“基于核的非线性联邦学习算法”，使用双随机梯度下降大幅提高计算速度，并通过增加扰动保证数据安全，在京东数科风控“联邦模盒”产品业务实践中，取得了较传统联合建模更优的效果。2022 年，蚂蚁集团开源了名为“隐语”的可信隐私计算框架^[14]，用一套通用框架统一支持了包括 MPC、TEE、FL、HE、DP 在内的多种主流隐私计算技术，可以对多种技术进行灵活组合，加强了联邦学习与其他隐私计算技术在现实应用中的深度融合应用。

4.2 医疗行业

医疗行业的数据面临隐私安全和标签缺失的双重挑战。一方面，受 HIPAA、GDPR 等法规限制，医疗机构无法直接交换原始数据；另一方面，医学影像与电子病历存在标签不全、标准异构等监督学习瓶颈。联邦学习通过参数隔离训练范式实现隐私合规协作，结合联邦迁移学习构建跨域特征映射，有效解决标签缺失问题。印度韦洛尔理工学院 S Shukla 等的研究证实^[15]：集成差分隐私的联邦框架（FL-DP）在乳腺癌检测任务中达成隐私-效能平衡（ $\epsilon=1.9$ 时准确率达 96.1%），为临床应用提供了可靠方案。除此以外，联邦学习技术还可用于中文医学影像报告自动生成^[16]、癫痫发作预测算法^[17]、口腔 X 光图像分类^[18] 等多种医疗诊断支持场景。

4.3 汽车行业

汽车产业智能化转型的核心矛盾在于车端实时决策安全性与全域数据协同效率的博弈，车联网作为“人-车-路”协同的关键载体已成为联邦学习研究前沿阵地，其面临的低延迟通信约束与多源异构感知融合挑战亟需联邦边缘协同解决。Quéméneur 等基于 MPI 架构开发轻量化联邦系统 FedPylot^[19]，通过 HPC 集群仿真验证客户端 FedOpt 加服务器端 FedAvgM 优化器组合的有效性，并对不同 YOLOv7 变体在准确性、推理速度和通信开销方面的权衡做出了系统分析；章航嘉等构建基于联邦学习和强化学习的车联网隐私保护和资源优化策略^[20]，使车联边缘网络系统总能耗降低 77%、传输数据量压缩 98.5%，显著优于传统

交互算法；林欣郁等设计了基于联邦深度强化学习任务卸载算法 (TOFDRL)^[21]，相比于传统的深度强化算法 MADRL 和基于规则的算法，平均响应时间分别缩短了 20.28% 与 18.82%。

5 总结与展望

本文系统阐述了联邦学习 (FL) 这一旨在破解数据隐私保护与价值挖掘矛盾的创新分布式机器学习范式。在日益严格的全球数据法规背景下，FL 以其“数据不动模型动”的核心机制，使多方能在不共享原始数据的前提下协作训练模型。文章介绍了 FL 的基本概念、典型流程（如 FedAvg 算法）及其多维分类体系。深入剖析了阻碍其大规模应用的关键挑战：数据异质性、模型异质性、通信瓶颈以及隐私安全，并概述了相应的主流解决思路。文章还展示了活跃的开源生态（如 FATE、SecretFlow）及 FL 在金融（跨机构风控推荐）、医疗（隐私合规诊断分析）、汽车（车联网协同优化）等领域的成功实践，彰显其巨大应用潜力。

展望未来，联邦学习研究与应用需在多方面持续深化：一方面，需着力突破性能与效率瓶颈，通过更先进的个性化策略、元学习方法、轻量化模型设计以及更智能的自适应通信优化技术（如压缩、稀疏化、动态调度），在极端异质性与资源约束下逼近集中式学习效能，并支持大规模物联网节点参与；另一方面，必须强化安全与隐私保障，深度融合如 TEE、同态加密、差分隐私等技术以高效抵御复杂攻击并平衡安全、效用与效率。同时，推动框架间标准化与互操作性、深化在智慧城市、供应链、跨学科科研及联邦大模型等新场景的应用、加强非凸及异步等复杂条件下的理论基础，亦是关键方向。最终，联邦学习有望成为构建安全、可信、高效协作型人工智能系统的基石技术。

参考文献

- [1] CHEUNG D W, NG V T, FU A W, et al. Efficient mining of association rules in distributed databases[J]. IEEE transactions on Knowledge and Data Engineering, 1996, 8(6): 911-922.
- [2] YU H, JIANG X, VAIDYA J. Privacy-preserving SVM using nonlinear kernels on horizontally partitioned data[C]//Proceedings of the 2006 ACM symposium on Applied computing. 2006: 603-610.
- [3] MCMAHAN H B, MOORE E, RAMAGE D, et al. Communication-Efficient Learning of Deep Networks from Decentralized Data[J]. arXiv preprint arXiv:1602.05629, 2016.
- [4] FederatedAI. FATE: An Industrial Grade Federated Learning Framework[CP/OL]. GitHub. 2019. <https://github.com/FederatedAI/FATE>.
- [5] IEEE Guide for Architectural Framework and Application of Federated Machine Learning[J/OL]. IEEE Std 3652.1-2020, 2021: 1-69. DOI: [10.1109/IEEESTD.2021.9382202](https://doi.org/10.1109/IEEESTD.2021.9382202).
- [6] YUAN X, LI P. On convergence of fedprox: Local dissimilarity invariant bounds, non-smoothness and beyond[J]. Advances in Neural Information Processing Systems, 2022, 35: 10752-10765.
- [7] KARIMIREDDY S P, KALE S, MOHRI M, et al. Scaffold: Stochastic controlled averaging for federated learning[C]//International conference on machine learning. 2020: 5132-5143.
- [8] JIN C, CHEN X, GU Y, et al. Feddyn: A dynamic and efficient federated distillation approach on recommender system[C]//2022 IEEE 28th international conference on parallel and distributed systems (ICPADS). 2023: 786-793.
- [9] ZHANG L, SHEN L, DING L, et al. Fine-tuning global model via data-free knowledge distillation for non-iid federated learning[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 10174-10183.

- [10] NISHIO T, YONETANI R. Client selection for federated learning with heterogeneous resources in mobile edge[C]//ICC 2019-2019 IEEE international conference on communications (ICC). 2019: 1-7.
- [11] ZHANG Z, CAO X, JIA J, et al. Fldetector: Defending federated learning against model poisoning attacks via detecting malicious clients[C]//Proceedings of the 28th ACM SIGKDD conference on knowledge discovery and data mining. 2022: 2545-2555.
- [12] ZHAO B, SUN P, WANG T, et al. Fedinv: Byzantine-robust federated learning by inverting local model updates[C]//Proceedings of the AAAI Conference on Artificial Intelligence: vol. 36: 8. 2022: 9171-9179.
- [13] FedlearnAI Team. Fedlearn: A Lightweight Federated Learning Framework for Industrial Applications [CP/OL]. GitHub. 2020. <https://github.com/fedlearnAI/fedlearn>.
- [14] GROUP A. SecretFlow: A Unified Framework for Privacy-Preserving Data Analysis and Machine Learning [CP/OL]. GitHub. 2021. <https://github.com/secretflow/secretflow>.
- [15] SHUKLA S, RAJKUMAR S, SINHA A, et al. Federated learning with differential privacy for breast cancer diagnosis enabling secure data sharing and model integrity[J]. Scientific Reports, 2025, 15(1): 13061.
- [16] 骆练, 黄保华, 张志诚, 等. 基于联邦多模态的中文医学影像报告自动生成模型[J]. 计算机工程与科学, 1-12.
- [17] 赵亦白. 基于联邦半监督学习的口腔 X 光图像分类研究[D]. 北京交通大学, 2024.
- [18] 丁驭岚. 基于联邦学习的癫痫发作预测算法研究[D]. 北京交通大学, 2024.
- [19] QUÉMÉNEUR C, CHERKAoui S. Fedpylot: Navigating federated learning for real-time object detection in internet of vehicles[J]. arXiv preprint arXiv:2406.03611, 2024.
- [20] 章航嘉, 谢志军. 基于强化学习的车联网隐私保护和资源优化策略[J]. 传感技术学报, 2022, 35(08): 1073-1079.
- [21] 林欣郁, 姚泽玮, 胡晟熙, 等. 车联网中基于联邦深度强化学习的任务卸载算法[J]. 计算机科学, 2023, 50(09): 347-356.